Programowanie w R wina

Adam Matuszczyk_MSAD 2018/19

11 07 2019

Praca zaliczeniowa z "Programowania w R" zajęć prowadzonych w ramach MSAD 2018/19

__na podstawie analiz prowadzonych na zajęciach przez Artura Machno oraz mapa świata wg. win wykonanana na podstawie wpisu, na portalu kaggle.com przez uczestnika o loginie **Pozdniakov**

```
library("tidyverse")
library("tidytext")
library("data.table")
library("plotly")
library("magrittr")
library("DT")
library("ggjoy")
```

Przeprowadzić analizę danych tekstowych w opisach win względem kraju pochodzenia. Proponuje podzielić kraje na 4 kategorie: US, France, Italy, Other.

```
wine<-fread("d:/AGH/Programowanie w R/wine.csv", header = TRUE, sep = ",")
wine <- wine[!is.na(price),][!country == "",] #chce usunąć wszystkie puste -bez informacji o kraju, cenach i
punktach</pre>
```

MAPA WIN

```
m <- as.data.table(map_data("world"))</pre>
#unique(wine$country)[!(unique(wine$country) %in% unique(m$region))]
#m[region == "US", region := "USA"]
wine[country == "US", country := "USA"]
m2 <- merge(m,
                    points = median(points, na.rm = T),
                    price = median(price, na.rm = T)),
                 by = country],
            by.x = "region",
            by.y = 'country',
            all.x = T,
            all.y = F,
            sort = F)
m2 <- m2[order(m2$order),]</pre>
m2[is.na(N), N:=0]
m2[,text:=sprintf("%s: %.0f wines <br/>br>Median points: %.0f <br/>br>Median price: %.0f$", region, N, points, price
g \leftarrow ggplot(m2, aes(text = text)) +
  geom_polygon(aes(long, lat, group = group, fill = N))+
  coord_equal()+
  scale_fill_gradient(low = '#c994c7', high = "#ddlc77", trans = "log", na.value = "#c994c7", breaks = c(0,
1, 10, 100, 1000, 10000))+
  theme_void()
gg <- ggplotly(g, tooltip = "text")</pre>
gg
```

Przeprowadzić analizę różnicy występowania słów w opisach w zależności od kraju pochodzenia wina Proponuje podzielić kraje na 4 kategorie: US, France, Italy, Other

Przeprowadzić analizę emocji w opisach win względem kraju pochodzenia Proponuje podzielić kraje na 4 kategorie: US, France, Italy, Other

porządkowanie danych

```
wine$country <- as.factor(wine$country)
fct_count(wine$country, sort = TRUE, prop = FALSE)</pre>
```

```
## # A tibble: 42 x 2
##
   f
##
   <fct>
             <int>
## 1 USA
            54265
## 2 France 17776
## 3 Italy
            16914
## 4 Spain
              6573
## 5 Portugal 4875
## 6 Chile
              4416
## 7 Argentina 3756
## 8 Austria
               2799
## 9 Australia 2294
## 10 Germany
               2120
\#\# \# ... with 32 more rows
```

```
wine$country <- fct_lump(wine$country, 3)
fct_count(wine$country, sort = TRUE, prop = FALSE)</pre>
```

```
## # A tibble: 4 x 2
## f n
## <fct> <int>
## 1 USA 54265
## 2 Other 31961
## 3 France 17776
## 4 Italy 16914
```

uporządkowanie danych do analizy dalszej

```
wine_spy <- wine %>% select( V1, country, description ) %>% unnest_tokens(word, description)#tokenizacja
```

usuwanie zbędnych elementów w ramce danych

```
#wszystkie słowa
count(wine_spy, word, sort = TRUE)
```

```
## # A tibble: 34,201 x 2
##
   word
   <chr>
##
           <int>
## 1 and 327806
         206309
## 2 the
## 3 a
          167413
## 4 of 162533
## 5 with 112581
## 6 this 106589
## 7 is
          88580
           70197
## 8 wine
## 9 flavors 60046
## 10 in
           59546
## # ... with 34,191 more rows
```

```
#wszystkie słowa bez "stop_words"

count(wine_spy %>%
    anti_join(stop_words), word, sort = TRUE)
```

```
## # A tibble: 33,534 x 2
    word
##
    <chr> <int>
           70197
## 1 wine
## 2 flavors 60046
## 3 fruit 46126
## 4 aromas 37445
## 5 palate 36683
## 6 finish 33634
## 7 acidity 31501
## 8 tannins 28095
## 9 drink 27935
## 10 cherry 27815
## # ... with 33,524 more rows
```

```
#dodawanie elementów zbędnych do stop words
# słowa specyficzne dla win


my_stop_words <- rbind(stop_words, tibble(word = c("wine", "flavors", "aromas", "palate"),lexicon = "my"))

# modyfikujemy ramkę "win_spy"


wine_spy <- wine_spy %>% anti_join(my_stop_words)
```

najczęściej wystepujące słowa


```
wine_spy %>% count(word, sort = T) %>% filter(n > 15000) %>% mutate(word = reorder(word, n)) %>%
    ggplot(aes(x = word, y = n, fill= factor(word))) +
    geom_col(show.legend= FALSE) +
    xlab(NULL)+
    geom_boxplot(show.legend = FALSE) +
    coord_polar(direction = -1)
```




```
wine_spy %>% count(word, sort = T) %>% filter(n > 15000) %>% mutate(word = reorder(word, n)) %>%
    ggplot(aes(x = word, y = n)) +
    geom_col() +
    xlab(NULL) +
    geom_boxplot()+
    coord_flip()
```



Najczęściej występujące słowa ze względu na kraj pochodzenia wina






LOUGHRAN

```
loughran<- get_sentiments("loughran") # niestety słownik "nrc" wyleciał z pakietu "tidytext" unique(loughran$sentiment)
```

```
## [1] "negative" "positive" "uncertainty" "litigious"
## [5] "constraining" "superfluous"
```

```
#loughran
loughran_df <-
    wine_spy %>%
    left_join(loughran) %>%
    group_by(V1, sentiment) %>%
    summarise(n = n()) %>%
    ungroup() %>%
    spread(key = sentiment, value = n, fill = 0) %>%
    select(V1:uncertainty)
```

Najpopularniejsze słowa emocjonalne w opisach win



Związek emocji opisu z oceną wina w podziale na kraje

